



网络上的分布式变分贝叶斯学习

华俊豪

统计信息与图像处理研究中心，信息与电子工程学院，
浙江大学

huajh@zju.edu.cn

□ 研究课题：网络上的**分布式变分贝叶斯**算法研究

关键词：贝叶斯学习，分布式信号处理，传感器网络

理论+应用


- 研究背景
- 研究现状与研究动机
- 分布式变分贝叶斯算法
- 算法应用

□ 网络化模型

- 由分布在一定区域内的节点自组织成网络构成。
- 节点具有采集和处理数据的能力。
- 受能量，带宽和隐私保护的限制，各节点仅有，

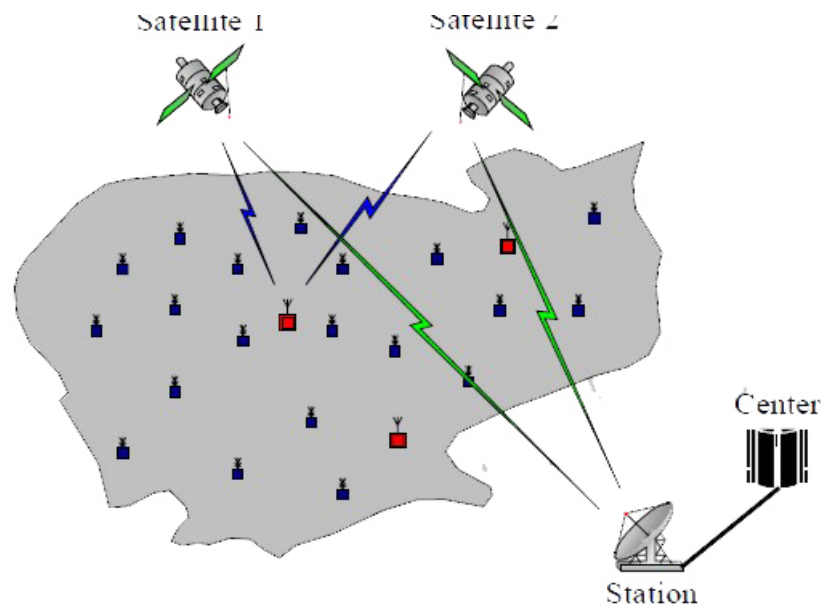
- 有限的计算能力，
- 有限的通信能力，
- 受保护的局部数据。

- 目的：通过节点之间的相互协作实现
分布式估计、推断、学习等任务。




□ (无线) 传感器网络

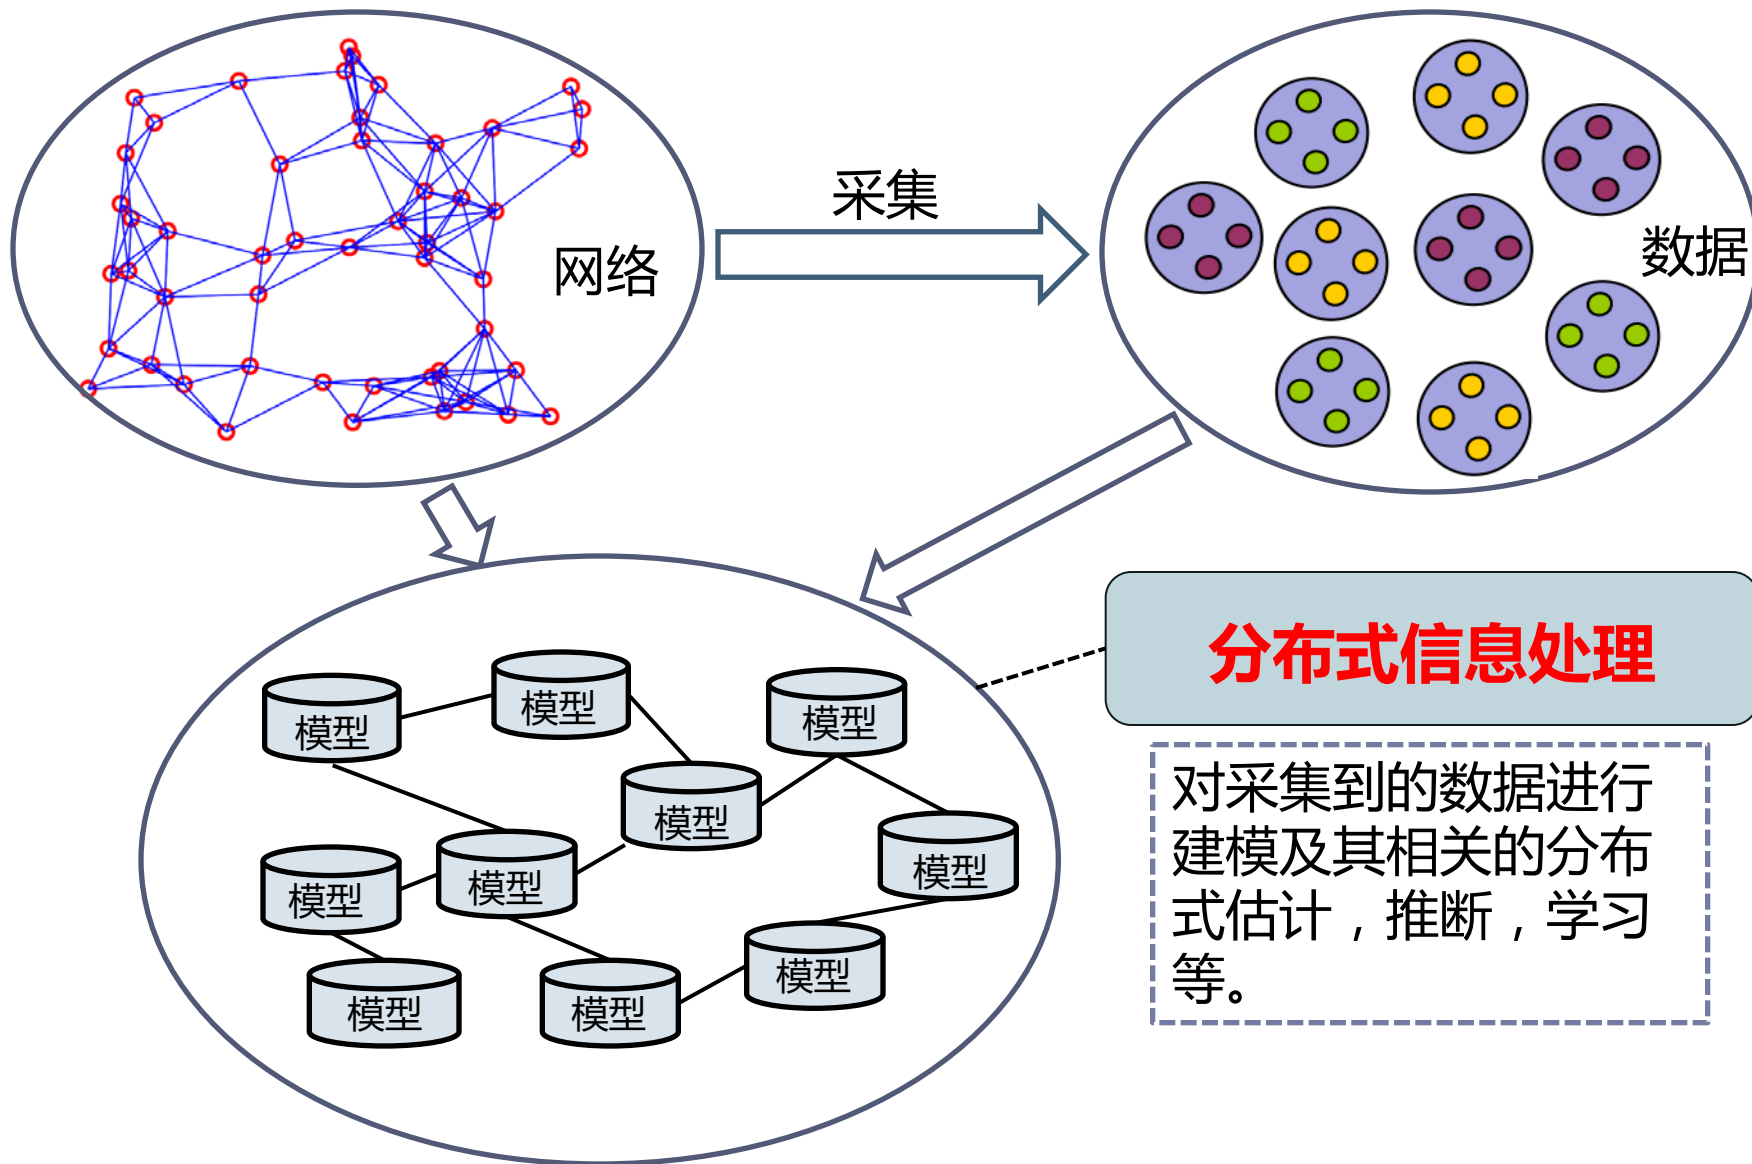
- 军事、农业、环境
- 定位、跟踪、监测



□ 分布式储存和计算机集群

- 互联网公司、医院、政府机构
- 海量数据挖掘、机器学习
- 大数据





- 研究背景
- **研究现状与研究动机**
- 分布式变分贝叶斯算法
- 算法应用

□ 涵盖各类学习问题

- 分布式参数估计
- 分布式状态跟踪
- 分布式聚类/分类
- 分布式检测等

□ 统计模型的设计：大多是基于频率统计

- 如统计假设检验，置信区间
- 最小二乘估计，GMM聚类
- 采用极大似然，EM算法



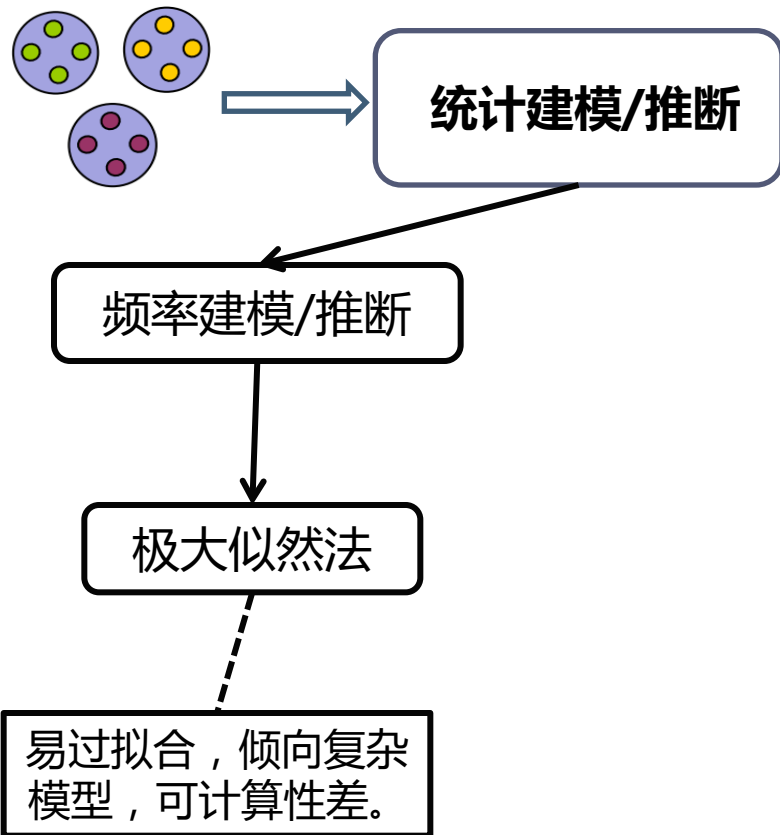
不考虑先验信息，强调数据出现频率或比例，从样本数据中得出结论

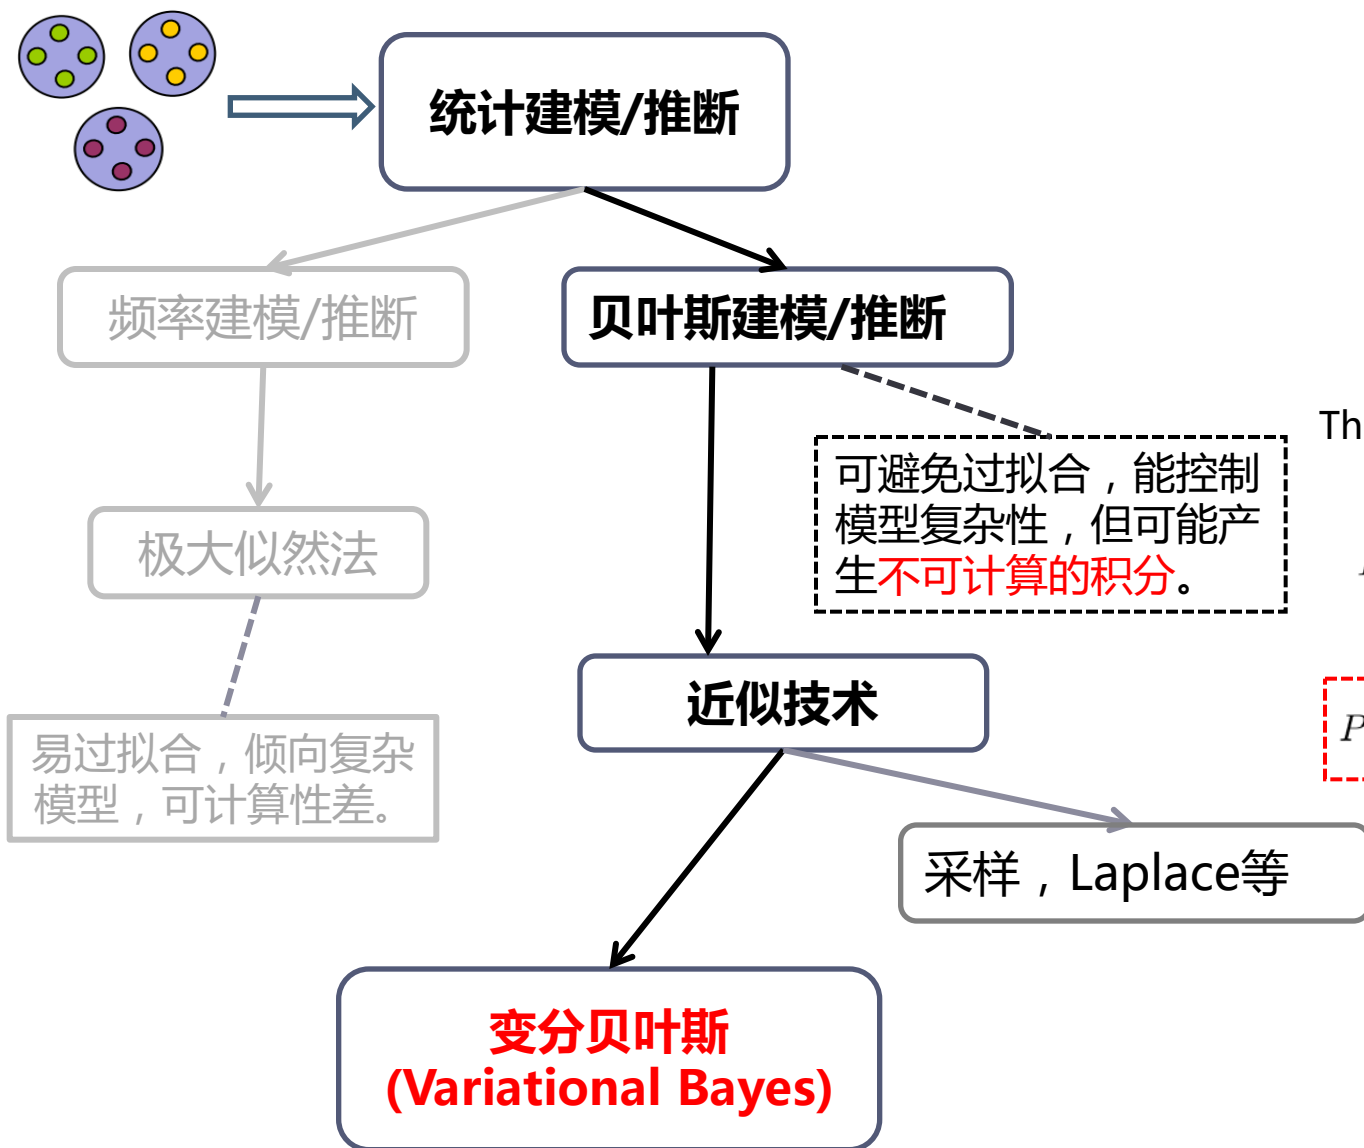
□ 贝叶斯建模

- 用一个先验分布来表达我们对未知数据的不确定性
- 能提供一种优雅的途径对大规模数据及其潜在的结构进行分析。
- 网络上的贝叶斯推断研究现状
 - 信息传递或置信传播(belief propagation)

缺点：需重构网络结构，生成树算法
 - 非参数化置信传播 (Monte Carlo + particle filtering)

缺点：计算量大





Thomas Bayes (1701-1761)

$$P(X|Y) = \frac{P(Y|X)P(X)}{P(Y)}$$


$$P(Y) = \int P(Y|X)P(X)dX$$

□ 原理

- 用一类简单可计算 (tractable) 的分布 Q 来近似真实分布 P 。
- 通过最小化 KL 散度，优化得到最优的变分分布 Q 。

□ 主要优势

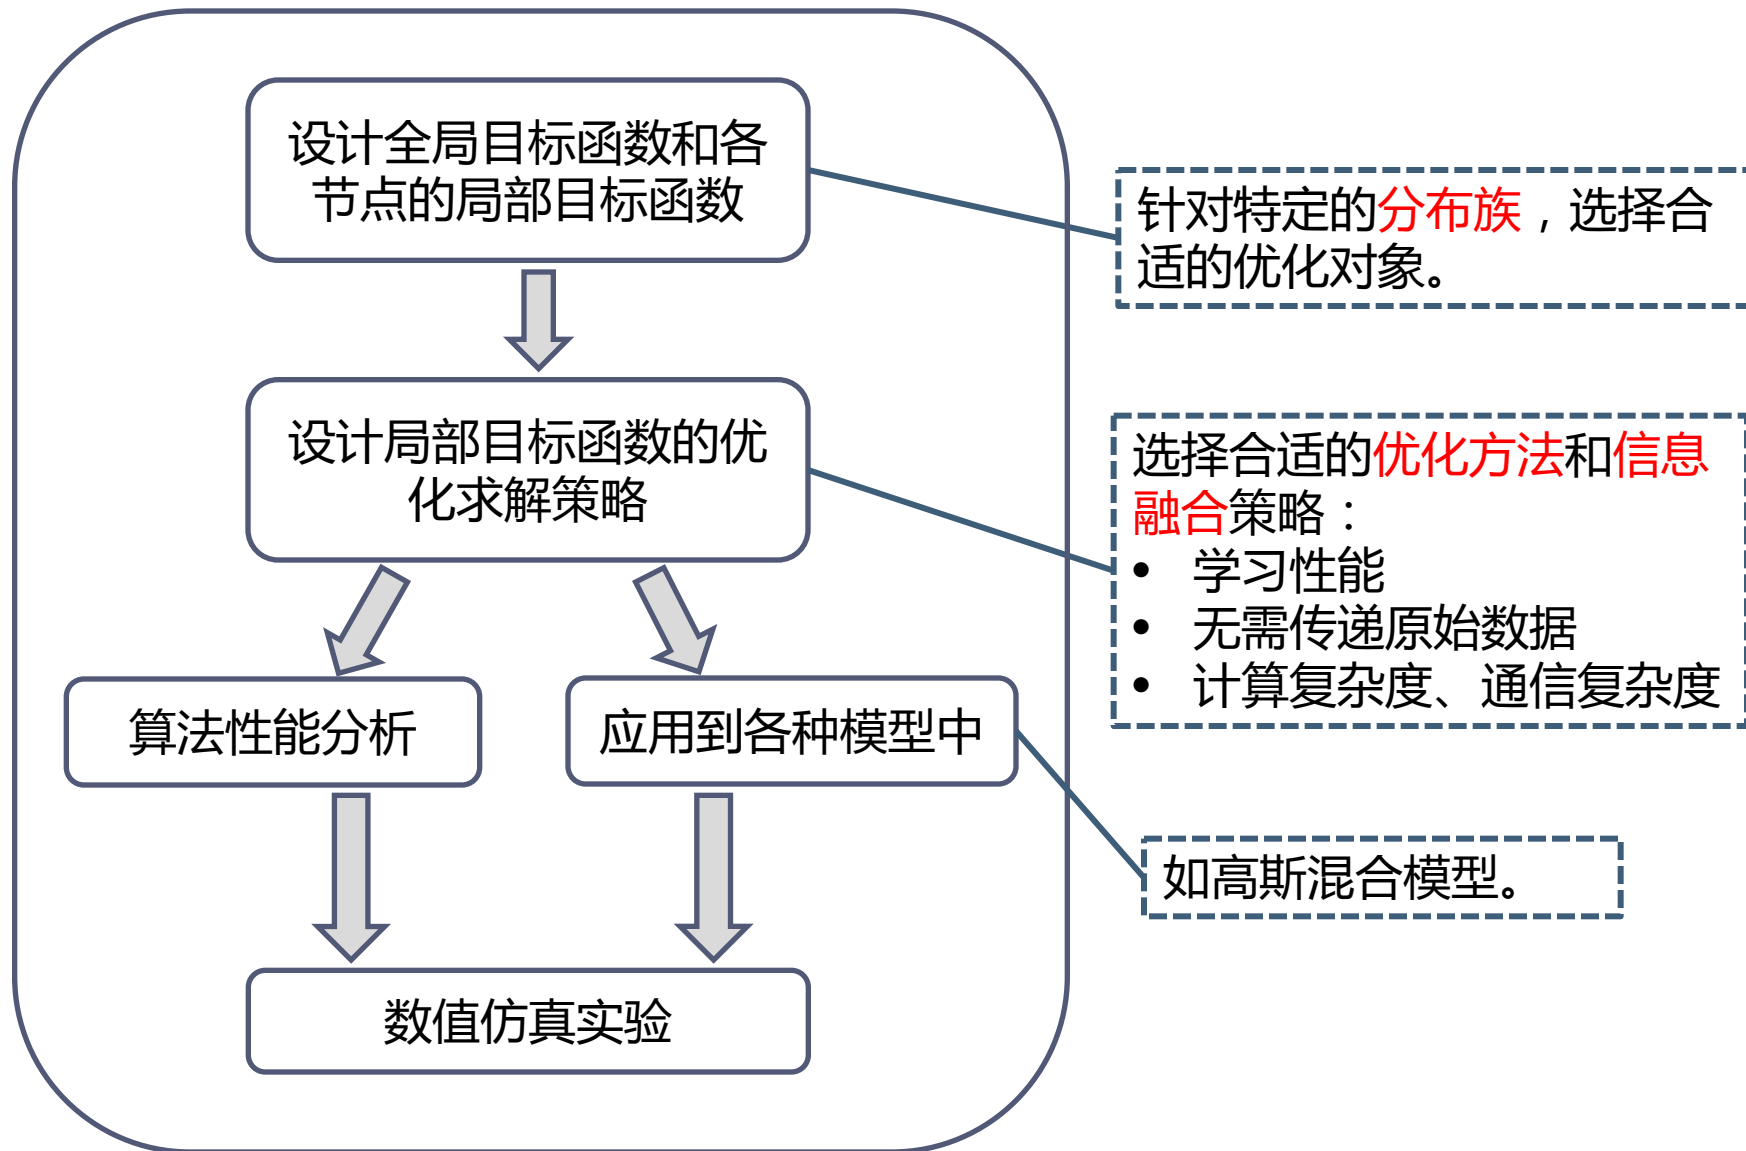
- 能得到参数和隐变量后验概率的解析表达式。
- 能推导出边缘似然函数 (证据) 的下界，用于模型选择。
- 同等精度下，变分贝叶斯方法比采样方法更快。



□ 应用

- 各类混合模型，概率主题模型，矩阵分解和时间序列分析等等。


- ❑ 研究背景
- ❑ 研究现状与研究动机
- ❑ 分布式变分贝叶斯算法**
- ❑ 算法应用



网络上的分布式变分贝叶斯框架

将全局目标函数分解为各局部目标函数的平均

$$\begin{aligned}\mathcal{L}(Q(z)) &= \mathbb{E}_Q[\log P(z, \mathbf{x})] + \mathbb{H}[Q(z)] \\ &= \frac{1}{N} \sum_{i=1}^N N \mathbb{E}_Q[\log P(\mathbf{x}_i | z)] + \mathbb{E}_Q\left[\frac{P(z)}{Q(z)}\right] \\ &= \frac{1}{N} \sum_{i=1}^N \mathcal{L}_i(Q(z)),\end{aligned}$$



考虑变分分布属于在共轭指数分布族。

将优化变量从变分分布等价地换成自然参数向量。

得到一般意义下的交替迭代框架：

$$\text{VBE} : \phi_{y_i}^* = \arg \max_{\phi_{y_i}} \mathcal{L}_i(\phi_{y_i}, \phi_{\theta}^*), \forall i = 1, \dots, N, \quad (17a)$$

$$\text{VBM} : \phi_{\theta}^* = \arg \max_{\phi_{\theta}} \sum_{i=1}^N \mathcal{L}_i(\phi_{y_i}^*, \phi_{\theta}). \quad (17b)$$

分布式计算

□ 分布式随机变分贝叶斯算法(dSVB)

- VBM求解方案：基于梯度的随机变分推断 + 扩散策略

$$\begin{aligned}\varphi_{\theta,i}^t &= \phi_{\theta,i}^{t-1} + \eta_t(\phi_{\theta,i}^{*,t} - \phi_{\theta,i}^{t-1}), \\ \phi_{\theta,i}^t &= \sum_{j \in \mathcal{N}_i \cup \{i\}} w_{ij} \varphi_{\theta,j}^t.\end{aligned}$$

一般性：
共轭指数分布族

□ 基于ADMM的分布式变分贝叶斯算法(dVB-ADMM)

- VBM求解方案：定义一个等价的优化问题 + ADMM优化

$$\begin{aligned}\min_{\phi_{\theta,i}, \varphi_{\theta,i,j}} \quad & \frac{1}{2} \sum_{i=1}^N \|\phi_{\theta,i} - \phi_{\theta,i}^*\|_F^2 \\ \text{s.t.} \quad & \phi_{\theta,i} = \varphi_{\theta,i,j}, i = 1, \dots, N, j \in \mathcal{N}_i, \\ \text{s.t.} \quad & \varphi_{\theta,i,j} = \phi_{\theta,j}, i = 1, \dots, N, j \in \mathcal{N}_i.\end{aligned}$$

- ❑ 研究背景
- ❑ 研究现状与研究动机
- ❑ 分布式变分贝叶斯算法
- ❑ 算法应用

□ 高斯混合模型: $p(\mathbf{x}_{ij}|\boldsymbol{\pi}, \boldsymbol{\mu}, \boldsymbol{\Lambda}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_{ij}|\boldsymbol{\mu}_k, \boldsymbol{\Lambda}_k^{-1}),$

□ 应用于分布式密度估计问题, 聚类问题

□ 多层贝叶斯模型

□ 变分分布

$$P(\{\mathbf{x}_i\}_N|\mathbf{y}_i, \boldsymbol{\mu}, \boldsymbol{\Lambda}) = \prod_{j=1}^{N_i} \prod_{k=1}^K \mathcal{N}(\mathbf{x}_{ij}|\boldsymbol{\mu}_k, \boldsymbol{\Lambda}_k^{-1})^{N \cdot y_{ijk}},$$

VBE: $q^*(\mathbf{y}_i) = \prod_{j=1}^{N_i} \text{Mult}(1, r_{ij1}, \dots, r_{ijK}),$

$$P(\mathbf{y}_i|\boldsymbol{\pi}) = \prod_{j=1}^{N_i} \text{Mult}(1, \boldsymbol{\pi}),$$

VBM: $q^*(\boldsymbol{\pi}_i) = \text{Dir}(\alpha_{i1}, \dots, \alpha_{iK}),$
 $q^*(\boldsymbol{\mu}_{ik}, \boldsymbol{\Lambda}_{ik}) = \mathcal{N}(\mathbf{m}_{ik}, (\beta_{ik} \boldsymbol{\Lambda}_{ik})^{-1}) \mathcal{W}(W_{ik}, \nu_{ik}), \forall k,$
 全局变分分布

$$P(\boldsymbol{\pi}) = \text{Dir}(K, \alpha_0),$$

□ 全局自然参数向量

$$P(\boldsymbol{\mu}|\boldsymbol{\Lambda}) = \prod_{k=1}^K \mathcal{N}(\boldsymbol{\mu}_0, (\beta_0 \boldsymbol{\Lambda}_k)^{-1}),$$

$$\boldsymbol{\phi}_{\boldsymbol{\pi}_i} = [\alpha_{i1} - 1, \dots, \alpha_{iK} - 1]^T.$$

$$P(\boldsymbol{\Lambda}) = \prod_{k=1}^K \mathcal{W}(\mathbf{W}_0, \nu_0).$$

$$\boldsymbol{\phi}_{\boldsymbol{\mu}_{ik}, \boldsymbol{\Lambda}_{ik}} = \begin{bmatrix} \frac{\nu_{ik} - D}{2} \\ -\frac{1}{2} \mathbf{W}_{ik}^{-1} - \frac{\beta_{ik}}{2} \mathbf{m}_{ik} \mathbf{m}_{ik}^T \\ \beta_{ik} \mathbf{m}_{ik} \\ -\frac{1}{2} \beta_{ik} \end{bmatrix}, \forall k = 1, \dots, K.$$

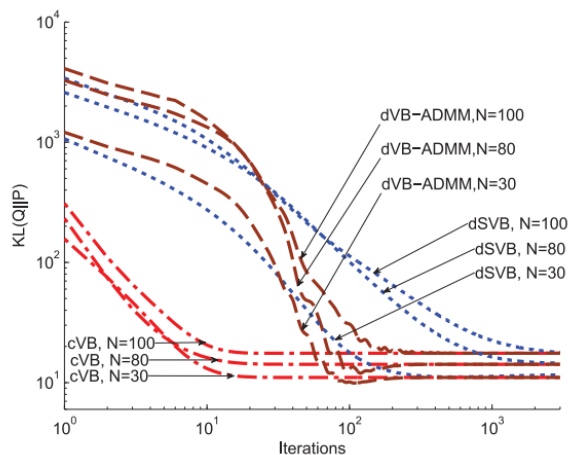



Fig. 10. The average performance of the dSVB and dSVB-ADMM with different network sizes ($N = 30, 80, 100$). The tuning parameters are set as $\tau = 0.2$, $\rho = 0.5$ for all cases.




Fig. 9. The number of data at each node (top) and the average performance (bottom) of the dSVB and dVB-ADMM with the imbalanced data, compared with the nsg-dVB and cVB.




Fig. 13. Accuracy versus the number of clusters on the COIL-20 dataset.

□ 分布式变分贝叶斯(dVB)算法的其他应用

□ 稀疏信号重建：分布式贝叶斯压缩感知，联合稀疏贝叶斯学习

- 研究基于dVB的贝叶斯压缩感知算法，实现传感器网络上的**联合稀疏**信号重建。（进行中）

□ 目标跟踪：卡尔曼滤波

- 研究**非高斯**噪声下的状态空间模型，并用dVB算法实现在分布式网络环境下的目标跟踪。（进行中）

□ 目标识别：贝叶斯多目标分类，多任务高斯过程

- 研究基于dVB的贝叶斯多任务学习，并应用到雷达传感器网络上的目标识别。

- **Junhao Hua**, Chunguang Li, “Distributed Variational Bayesian Algorithms Over Sensor Networks”, *IEEE Transactions on Signal Processing*, vol.64, no.3, pp.783-798, Feb. 2016.
- **Junhao Hua**, Chunguang Li, Hui-Liang Shen, “Distributed Learning of Predictive Structures from Multiple Tasks Over Networks”, *IEEE Transactions on Industrial Electronics*, preprint, Jul. 2016, DOI: 10.1109/TIE.2016.2588463.
- **Junhao Hua**, Chunguang Li, Distributed Joint Sparse Recovery with Beta Process Prior via Quantized Communication, preparing.
- **Junhao Hua**, Chunguang Li, Distributed Robust Kalman Filtering By Variational Bayesian Approximations, preparing.